Universität Bielefeld

Pictogramm-Plots mit R: pic.plot()

— Hans Peter Wolf[a] —

Econometrics Comp. Statistics

Ziel

Ziel statistischer Graphiken ist die **Repräsentation** von Datengefügen, um Werte, Anzahlen, Verhältnisse, Zusammenhänge, Strukturen usw. unmittelbar sehen zu können, [1], [5], [8].

Beispiele ($\mapsto$ steht für *repräsentieren*):

Stem and leaf	Ziffern, y-Werte $\mapsto$ Objekte, Größen
Scatterplot	Koordinaten $\mapsto$ Messwerte
Stabdiagramm	Stablängen $\mapsto$ Häufigkeiten
Kreisdiagramm	Sektoren $\mapsto$ Anteile
Boxplot	Elemente $\mapsto$ Extrema, Angeln, Ausreißer
Chernoff face	Gesichtselemente $\mapsto$ Ausprägungen
Dendrogramm	Verbindungshöhen $\mapsto$ Distanzen
Mosaic-Plot	Flächen $\mapsto$ Häufigkeiten

Farbe, Form, Symbol, Größe $\mapsto$ Infos, Gruppeneigenschaften

Ziel für `pic.plot()`: Visualisierung von Kontingenztabellen

Repräsentation von Objekten und Anzahlen

- Darstellung einzelner Objekte $\rightarrow$ Punkte, Symbole, Bilder:

- Darstellung von 19 Objekten $\rightarrow$ Reihe von Symbolen:

- Anzahlen $\rightarrow$ Aufteilung der Reihe auf mehrere **Stacks**
  für 19 Objekte $\rightarrow$ mit drei Stacks (mit max. Länge 8):

- Unterscheidung von Gruppen durch verschiedene Symbole
  $\rightarrow$ 12 bzw. 7 Strichmännchen zweier Gruppen:

- Unterscheidung von Gruppen durch Symbole *und* Farben:

Das Projekt `pic.plot()`

- Urknall: R-Package `aplpack` – [6], Logo-Diskussionen sowie `pictogram()` von Ulrike Grömping, [2].
- Vision: Visualisierung mehrdimensionaler Häufigkeitstabellen mittels Repräsentation der zugrundeliegenden Elemente durch Pictogramme in schachbrettartigen Feldern (Panels).
- Anforderungen, die bisher erfüllt wurden:
  - schachbrettartige Zerlegung der Ausgabefläche in *Panels*
  - wiederholte Zerlegung der Fläche: horizontal wie vertikal
  - gruppenabhängige Farb- und Symbol-Wahl
  - einfache Bediensprache für Zerlegung, Farb-, Symbol-Wahl
  - Inputs aus den Klassen `table` und `data frame`
  - Transformation numerischer Größen
  - Verarbeitung gebrochener und negativer Einträge
  - Größen- und Randmodifikation für die Panels
  - diverse Layout-Anordnungen für Pictogramme in Panels
  - Symbole, Liniengraphiken und Bilder als Pictogramme
  - Erklärungstexte: Randbeschriftungen und Legenden
  - Verfeinerungen durch Low-Level-Routinen

[a]Hans Peter Wolf, Fak. für Wirtschaftswissenschaften, Uni Bielefeld, e-Mail: pwolf@wiwi.uni-bielefeld.de

User Interface

Um die Argumentenvielfalt beherrschbar zu machen, erhielten Argumente je nach Kontext gleiche Namensanfänge (`grp, panel, pic, lab`). Die hinteren Namensteile weisen auf die Konfigurationszwecke hin (z. B. `cex, frame, space.factor`).
Die zulässigen Wertemengen wurden für die intendierten Fälle möglichst sinnvoll und sparsam entworfen. So lassen sich Zerlegungen der Ausgabefläche in x- und y-Richtung durch R-Formeln mit Variablennamen wie bei linearen Modellen ausdrücken. Variablen können aber auch einfach über Dimensionsnummern referenziert werden. Taucht auf der linken bzw. rechten Seite von ~ mehr als eine Variable auf – verbunden durch ein +-Zeichen –, führt das zu verschachtelten Zerlegungen des x- bzw. y-Bereichs.

Argumente von `pic.plot()`

Liste wichtiger Argumente mit Bedeutungshinweisen:

Bezug	Argument	Bedeutung
Input	`data`	Input: Tabelle oder data frame
Input	`vars.to.factors`	Transformation von Zahlen in factors
Gruppierung	`grp.xy`	Variablen für horizontale / vertikale Zerlegung
Gruppierung	`grp.color`	Variable für Farb-Wahl
Gruppierung	`grp.pic`	Variable für Pictogramm-Wahl
Gruppierung	`colors`	Menge der Farben
Gruppierung	`pics`	Menge der Pictogramme
Panels	`panel.prop.to.size`	Festlegung der Panelgrößen
Panels	`panel.margin`	Größen der Ränder
Panels	`panel.space.factor`	Zwischenraum zwischen Panels
Panels	`panel.frame`	Umrahmung der Panels
Pictogramme	`pic.horizontal`	horizontale oder vertikale Stacks
Pictogramme	`pic.stack.type`	Layout-Typ für Pictogramm-Platzierung
Pictogramme	`pic.cex`	Symbol-Größe
Pictogramme	`pic.aspect`	Symbol-Seitenverhältnis
Pictogramme	`pic.space.factor`	Zwischenraum zwischen Pictogrammen
Pictogramme	`pic.frame`	Umrahmung der Pictogramme
Beschriftung	`lab.side`	Seiten für Randbeschriftungen
Beschriftung	`lab.cex`	Beschriftungsgröße
Beschriftung	`lab.boxes`	Hintergrund für Randbeschriftungen
Beschriftung	`main`	Titel

Bereitstellung und weiteres Vorgehen

- Stand:
  - Konzept und Struktur von `pic.plot()` steht.
  - Alle wesentlichen Programm-Teile sind umgesetzt.
  - Demo mit über 75 Beispielen liegt als .R- und PDF-File vor.
  - Aktuelle Dateien zu `pic.plot()` sind zu finden unter [7]: Funktionsdefinition `pic.plot.R`, Beispiele: `pic.demo.pdf`
- Plan:
  - Check der Argumentenliste: Bezeichnungen, Wirkungen
  - Entwurf weiterer Generierungsfunktionen für Pictogramme
  - Durchführung zusätzlicher Tests
  - Aktualisierung der help page
  - Integration in das R-Paket `aplpack`
  - Bereitstellung der neuen Version von `aplpack` über CRAN

Quellen

[1] J. M. Chambers, W. S. Cleveland, B. Kleiner, P. A. Tukey (1988): Graphical Methods for Data Analysis.

[2] U. Grömping (2015): `pictogram`, R package version 1.0-3, private communications.

[3] M. Mazziotta, A. Pareto (2014): Non-compensatory Aggregation of Social Indicators: An Icon Representation. In: F. Crescenzi, S. Mignani (eds.), Statistical Methods and Applications from a Historical Perspective, Studies in Theoretical and Applied Statistics.

[4] D. Meyer, A. Zeileis, K. Hornik (2006): The Structplot Framework: Visualizing Multi-way Contingency Tables with vcd. Journal of Statistical Software, 17(3), 1–48.

[5] E. R. Tufte (2001): The visual Display of Quantitative Information.

[6] H. P. Wolf (2015): `aplpack`, R package version 1.3.0,
URL: `https://cran.r-project.org/web/packages/aplpack`

[7] H. P. Wolf (2016): Web-Seite zu `aplpack`,
URL: `http://www.wiwi.uni-bielefeld.de/lehrbereiche/statoekoinf/comet/wolf/wolf_aplpack`

[8] F. W. Young, P. M. Valero-Mora, M. Friendly (2006): Visual Statistics.

Anhang: Beispiele

Folgende Beispiele stammen aus der oben erwähnten Demo, siehe [7].

HairEyeColor: Geschlecht, Haarfarbe der Personen hervorgehoben

```
> pic.plot(aperm(HairEyeColor, c(2,1,3)), grp.xy = NULL,
+          grp.pic           = Sex,
+          grp.color         = Hair,
+          pics              = c(15, 17),
+          colors            = c("black", "brown", "red",
+                                "yellow2"),
+          pic.frame         = FALSE,
+          pic.space.factor  = 0,
+          lab.parallel      = FALSE,
+          main = "grouping by color and central symbols")
```

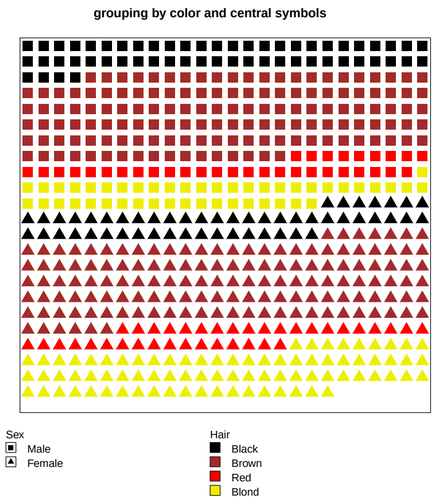

HairEyeColor: gruppiert nach Hair, Sex, ohne Space

```
> pic.plot(HairEyeColor,
+          grp.xy     = Hair ~ Sex,
+          grp.color  = Sex,
+          colors     = c("blue", "pink"),
+          pic.frame  = FALSE,
+          pic.space  = 0,
+          main = "grouping by x and y and by colors")
```

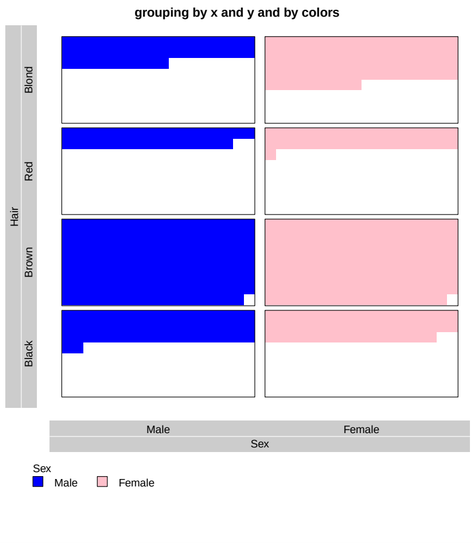

HairEyeColor: x-Bereich zerlegt nach Hair, Eye

```
> pic.plot(HairEyeColor,
+          grp.xy          = . ~ 1 + 2,
+          grp.color       = 3,
+          pic.stack.type  = "bl",
+          lab.parallel    = c(FALSE, NA, TRUE),
+          pic.aspect      = .5,
+          panel.frame     = FALSE,
+          lab.color       = "lightblue",
+          lab.boxes       = 0,
+          lab.cex         = 0.8,
+          main = "grouping 2 vars in x, compact labs")
```

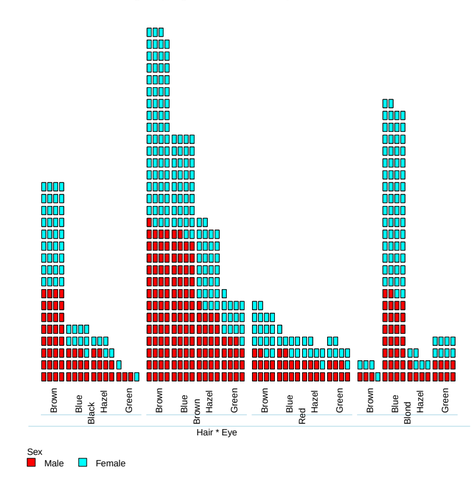

HairEyeColor: y-Bereich zerlegt nach Eye, Hair, Sex

```
> pic.plot(HairEyeColor,
+          grp.xy          = 2 + 1 + 3 ~ .,
+          grp.color       = 3,
+          pic.aspect      = .3,
+          pic.stack.type  = "lt",
+          pic.frame       = FALSE,
+          panel.frame     = FALSE,
+          lab.parallel    = c(FALSE, FALSE, TRUE),
+          lab.color       = "lightgreen",
+          lab.boxes       = FALSE,
+          lab.cex         = 0.7,
+          lab.n.max       = c(3,32),
+          main = "groupings: by 2+1+3~. and by col")
```

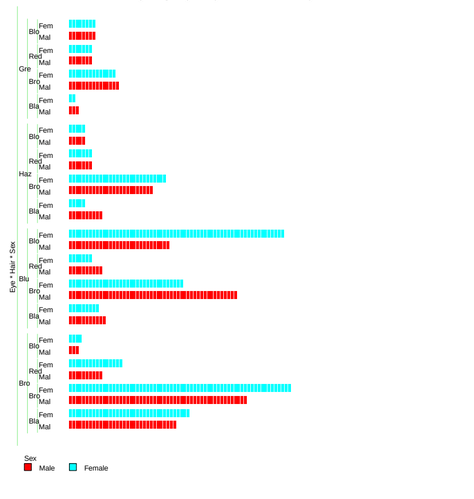

Titanic: Panelgrößen gemäß Randhäufigkeiten

```
> pic.plot(Titanic,
+          grp.xy             = 3 ~ 1,
+          grp.color          = 4,
+          pic.space.factor   = 0.5,
+          panel.prop.to.size = c(TRUE, TRUE), # <-
+          lab.boxes          = 0.3,
+          lab.color          = "lightgreen",
+          main = "xy: 'Age', 'Class' / color: 'Survived'")
```

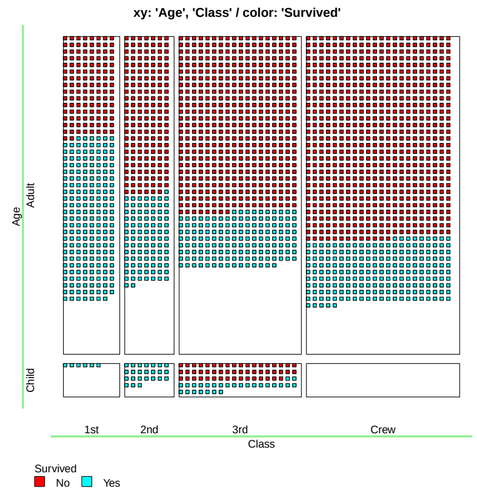

HairEyeColor: Mosaic-Plot versus Pictogramm-Plot, [4]

```
> par(mfrow = 2:1)
> mosaicplot(HairEyeColor)
> pic.plot(HairEyeColor,
+          grp.xy             = 2 ~ 1 + 3 ,
+          lab.parallel       = c(TRUE, TRUE, TRUE),
+          colors             = "red",
+          pic.space.factor   = 0.5,
+          pic.aspect         = 2,
+          panel.reverse.y    = TRUE,
+          panel.prop.to.size = TRUE,
+          lab.cex            = .6,
+          lab.boxes          = 1,
+          lab.color          = "grey",
+          panel.margin       = c(0.00,.035,0.0,.050),
+          main = 'HairEyeColor: grp.xy = 2 ~ 1 + 3')
> par(mfrow=c(1,1))
```

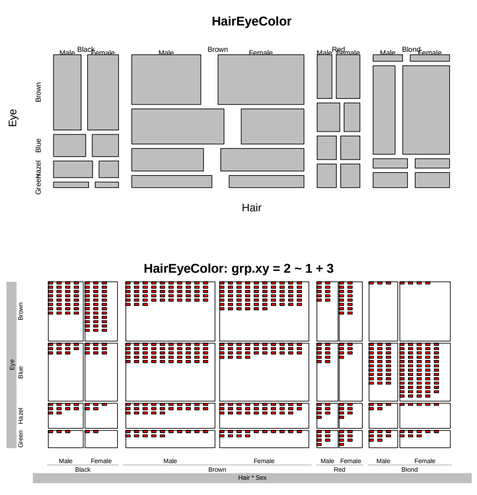

Titanic: gebrochene Pictogramme durch 10-Personen-Einheiten

```
> pic.plot(margin.table(Titanic / 10, c(1,3,4)),
+          grp.xy             = 2 ~ 1,
+          grp.color          = 3,
+          panel.prop.to.size = c(TRUE, TRUE),
+          main = "xy:'Age' / 'Class', colors:'Survived'")
```

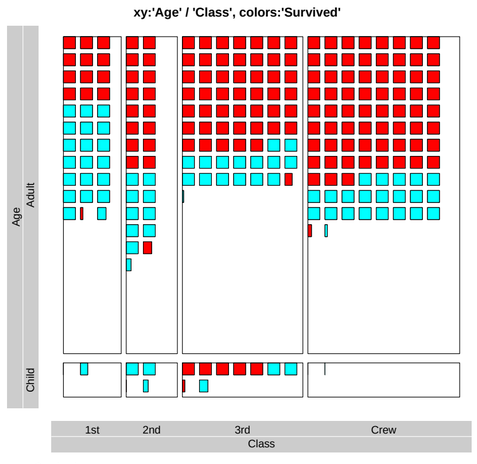

Bevölkerungspyramide, Einheit der Daten: in Tausend

```
> pic.plot(mw,
+          grp.xy             = 2 ~ 1,
+          grp.color          = 1,
+          pic.aspect         = 2,
+          pic.stack.type     = rep(c("t", "b"), nrow(mw)),
+          pic.horizontal     = FALSE,
+          pic.space.factor   = 0,
+          pic.frame          = FALSE,
+          panel.frame        = FALSE,
+          panel.space.factor = c(.0, .02),
+          lab.n.max          = c(2, 10),
+          main = paste("Pyramide einer Population, 2014"))
```


Titanic: Häufigkeiten relativ zur Maximalzahl

```
> pic.plot(Titanic / max(Titanic),
+          grp.xy             = 1 ~ 2 + 3,
+          grp.color          = 4,
+          colors             = c("black", "green"),
+          pic.stack.type     = "b",
+          pic.horizontal     = FALSE,
+          panel.frame        = FALSE,
+          panel.space.factor = 0.05,
+          pic.space.factor   = 0.103,
+          pic.aspect         = 0.5,
+          main = "Titanic: relative frequencies")
```

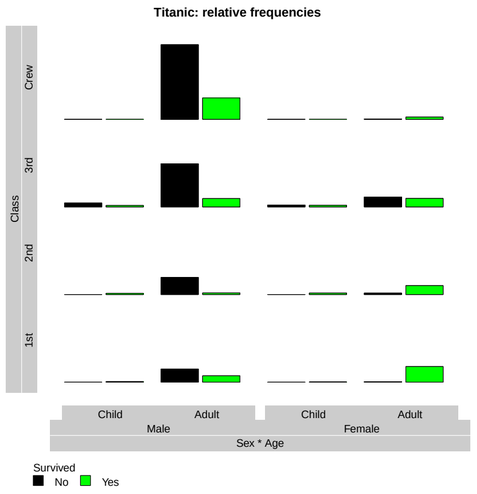

trees: konstruierte Rastergraphik zur Baumrepräsentation

```
> n <- 200; m <- n/2; x <- y <- seq(n <- 200); f <- floor
> image1 <- (outer( (x-m)^2, (y-m)^2, FUN="+") > (.8*m)^2 )
> image2 <- (outer( (x-m)^2, (y-m)^2, FUN="+") > (.6*m)^2 )
> image3 <- image1 | !image2; image3[,f(.75*n):n] <- 1
> image3[f(0.47*n):f(0.4*n), f(.05*n):f(.65*n)] <- 0
> image3[f(0.53*n):f(0.6*n), f(.05*n):f(.60*n)] <- 0
> image <- as.raster(image3)
> pic.plot(trees,
+          grp.xy           = 1 ~ 2,
+          grp.color        = 3,
+          grp.pic          = 3,
+          colors           = c("red", "blue", "green"),
+          pics             = image,
+          pic.draft        = FALSE,
+          pic.frame        = FALSE,
+          vars.to.factors  = c(.3, 4, .3),
+          lab.boxes        = 1,
+          main             = "second raster pictogram plot")
```

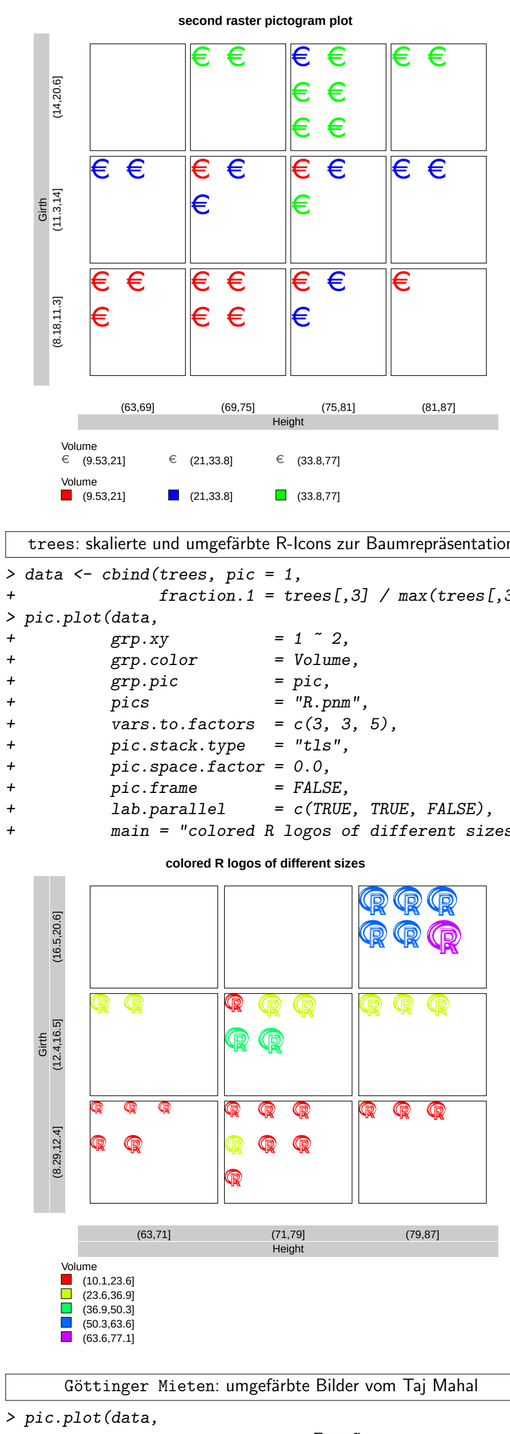

trees: skalierte und umgefärbte R-Icons zur Baumrepräsentation

```
> data <- cbind(trees, pic = 1,
+               fraction.1 = trees[,3] / max(trees[,3]) )
> pic.plot(data,
+          grp.xy           = 1 ~ 2,
+          grp.color        = Volume,
+          grp.pic          = pic,
+          pics             = "R.pnm",
+          vars.to.factors  = c(3, 3, 5),
+          pic.stack.type   = "tls",
+          pic.space.factor = 0.0,
+          pic.frame        = FALSE,
+          lab.parallel     = c(TRUE, TRUE, FALSE),
+          main = "colored R logos of different sizes")
```

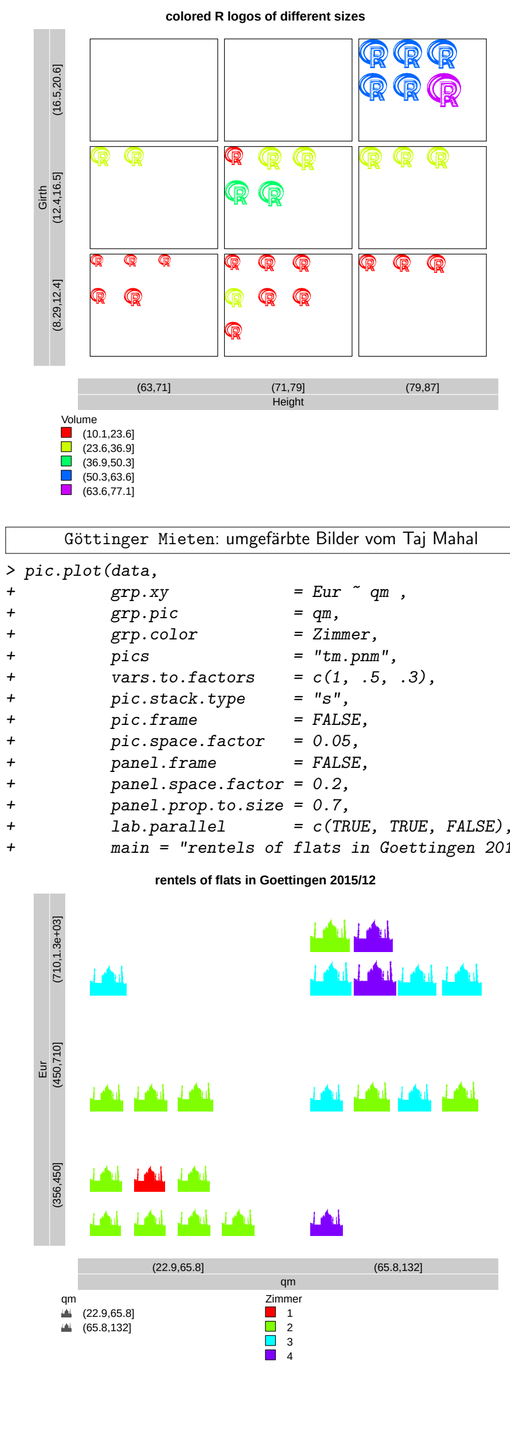

Titanic: Ergänzung von Texten

```
> pic.plot(margin.table(Titanic / 10, c(1,3,4)),
+          grp.xy             = 2 ~ 1,
+          grp.color          = 3,
+          panel.prop.to.size = c(TRUE, TRUE),
+          main = "xy:'Age' / 'Class', colors:'Survived'")
```

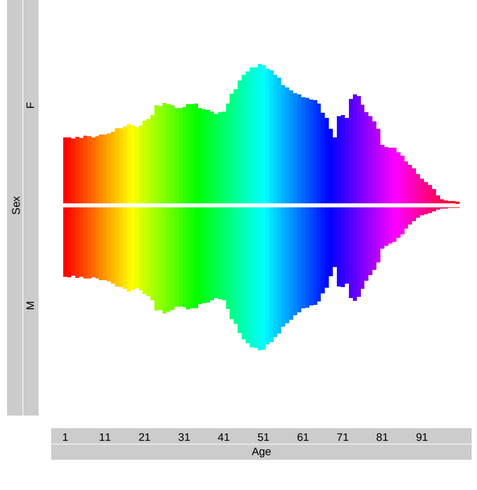

Göttinger Mieten: umgefärbte Bilder vom Taj Mahal

```
> pic.plot(data,
+          grp.xy           = Eur ~ qm ,
+          grp.pic          = qm,
+          grp.color        = Zimmer,
+          pics             = "tm.pnm",
+          vars.to.factors  = c(1, .5, .3),
+          pic.stack.type   = "s",
+          pic.frame        = FALSE,
+          pic.space.factor = 0.05,
+          panel.frame      = FALSE,
+          panel.space.factor = 0.2,
+          panel.prop.to.size = 0.7,
+          lab.parallel     = c(TRUE, TRUE, FALSE),
+          main = "rentels of flats in Goettingen 2015/12")
```


Traveller Icons zur Indikatorenrepräsentation, [3]

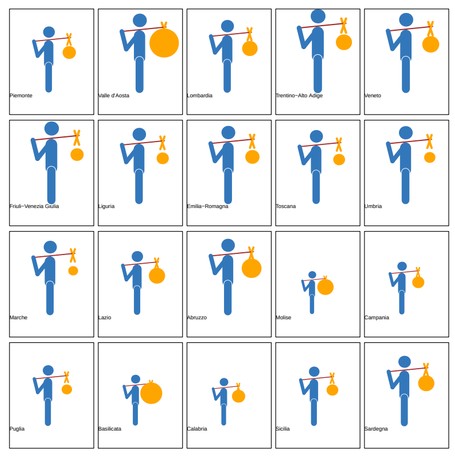

trees: Pictogramme erzeugt durch eine Generierungsfunktion

```
> smiley.gen <- function(data.row = NULL){
+   if(0 < length(data.row)){
+     idx <- as.numeric(rownames(data.row))
+     h <- min(trees[, "Volume"])
+     smile <- (trees[idx,"Volume"]-h)/
+              (max(trees[,"Volume"])-h)
+     res <- smiley(smile = smile)
+   } else { res <- smiley() }
+   return(res)
+ }
> pic.plot(trees,
+          grp.xy           = Height ~ Girth,
+          grp.pic          = Volume,
+          grp.color        = Volume,
+          vars.to.factor   = c(.25, .3, .05),
+          pics             = smiley.gen,
+          pic.space.factor = 0.1,
+          pic.frame        = FALSE,
+          panel.frame      = FALSE,
+          main = "smileys represent trees")
```

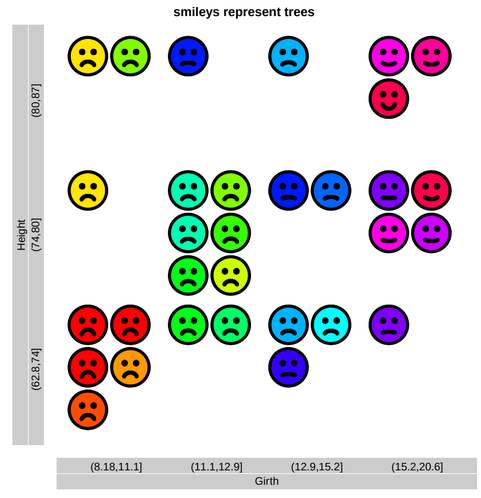

trees: Verwendung von faces() zur Volumenrepräsentation, [6]

```
> library(aplpack, lib.loc = "~/lib")
> faces.of.trees <- faces(trees, plot.faces = FALSE)
> f.list <- generate.fns(faces.of.trees, 1:31)
> pic.plot(trees,
+          grp.pic          = 3,
+          grp.col          = 3,
+          vars.to.factors  = c(.25, .3, .12),
+          pics             = f.list,
+          pic.space.factor = 0.3,
+          pic.frame        = FALSE,
+          panel.frame      = FALSE,
+          lab.cex          = 0.7,
+          lab.parallel     = c(TRUE, TRUE, FALSE),
+          main = "trees by faces and pic.plot")
```

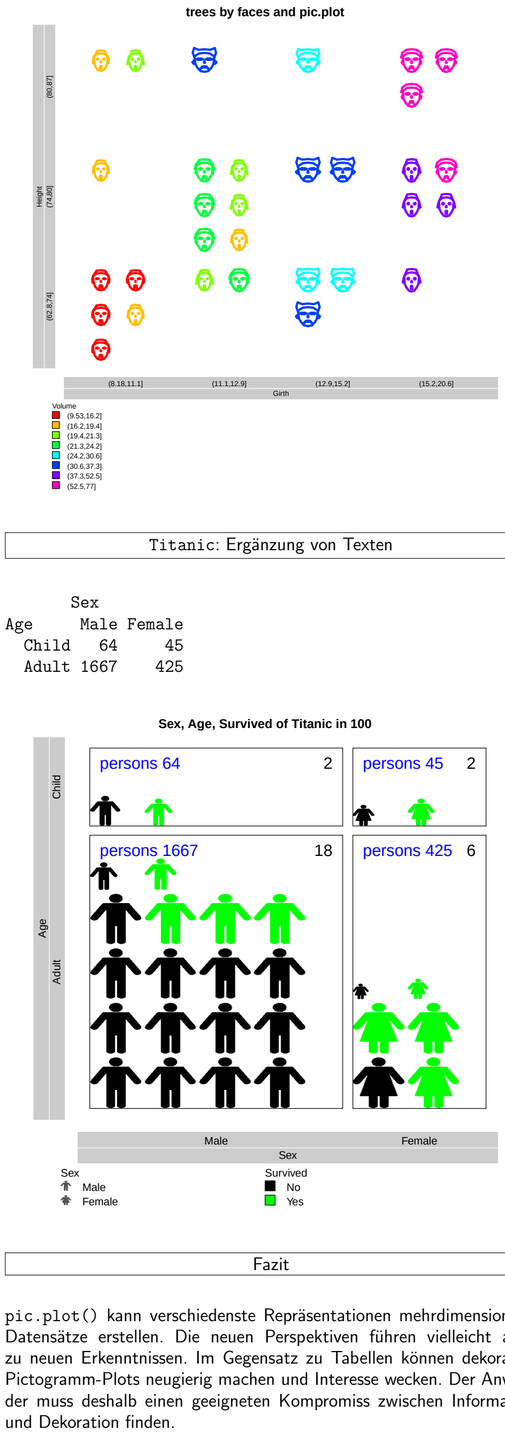

Titanic: Ergänzung von Texten

```
      Sex
Age     Male Female
  Child   64     45
  Adult 1667    425
```


Fazit

pic.plot() kann verschiedenste Repräsentationen mehrdimensionaler Datensätze erstellen. Die neuen Perspektiven führen vielleicht auch zu neuen Erkenntnissen. Im Gegensatz zu Tabellen können dekorative Pictogramm-Plots neugierig machen und Interesse wecken. Der Anwender muss deshalb einen geeigneten Kompromiss zwischen Information und Dekoration finden.